

Plan for dagen

- 09:30 : Dørene åpner, kaffe
- 09:45 : Introduksjon: Hva er Nasjonalbiblioteket og hvem er vi?
- 09:55: Presentasjon av NBs digitale ressurser:
 - <u>dhlab-api</u> / <u>pypi-pakke</u>
 - bildemateriale og multimodale embeddings
 - ressurskatalogen
 - whisper og andre språkmodeller
 - <u>nettbiblioteket</u> og deres <u>api</u>
- 10:45: Gruppene samles og hackinga starter!
- 12:00 : Felles lunsj
- 12:30 : Hackinga fortsetter
- 15:30 : Avslutning: Hvordan gikk det? Gruppene presenterer (kort) det de har laget



Hva er nasjonalbiblioteket?

Nasjonalbiblioteket er en statlig virksomhet som har som oppgave å samle inn, registrere, bevare og gi tilgang til publisert materiale fra alle publiseringsplattformer, og som gjennom dette er en viktig kilde til kunnskap om Norge og norske forhold.

Kilde: Kulturdepartementet

Se også: pliktavlevering



NBs digitale samling

Materialtype	Andel	Størrelse
Video og fjernsyn	22%	2860 TB
Film	21%	2730 TB
Aviser	19%	2470 TB
Nettarkiv	16%	2080 TB
Radio og lyd	12%	1560 TB
Bøker	8%	1040 TB
Foto	2%	260 TB





Hva er språkbanken?

Språkbanken er en nasjonal infrastruktur for språkteknologi.

Vi tilbyr språkteknologiressurser rettet mot forskere, studenter og virksomheter som utvikler språkteknologiske produkter

https://www.nb.no/sprakbanken/



Hva er DH-laben?

Laboratorium for digital humaniora som skal assistere forskere og studenter i bruk av digitale verktøy og metoder i humanistisk forskning

https://www.nb.no/forskning/digital-humaniora/

https://www.nb.no/dh-lab/



Hvem er vi?

Ingerid

Lars

Marie

Tita

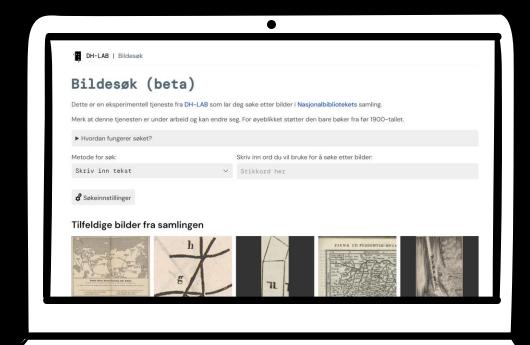


DHLAB api og python-pakke

https://www.nb.no/dh-lab/digital-tekstanalyse/



Bildesøkappen lar deg søke etter bilder i norske bøker fra før år 1900



https://dh.nb.no/run/bildesok/

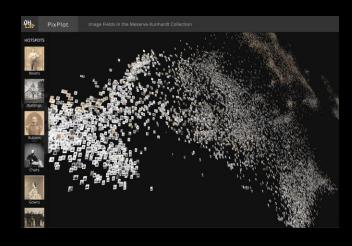
Vi har laget et datasett med 363061 bilder fra 16711 norske bøker i det fri (før 1900)

```
from pathlib import Path
import pandas as pd
import numpy as np
from PIL import Image
# Load the metadata
metadata = pd.read parquet("metadata.parquet")
# Open the image for the first row
image_file = Path("images") / metadata["file_name"][0]
image = Image.open(file name)
# Get SigLIP embedding matrix
embeddings = np.stack(metadata["SigLIP"].values)
```

Grundigere kodeeksempel her:

Ideer for videre arbeid

Lage kart med UMAP:



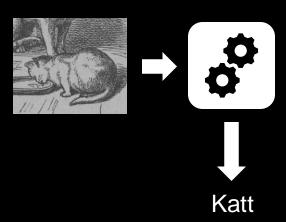
https://github.com/digitalme thodsinitiative/dmi_pix_plot

Bildemosaikk:



https://medium.com/@aaro ngrove/creating-imagemosaics-with-python-8e4c25dd9bf9

Trene en bildeklassifikator



Ressurskatalogen

https://www.nb.no/sprakbanken/ressurskatalog/

Inneholder ressurser for norsk språkteknologi, deriblandt:

- Tekstdatasett (<u>Idiom</u>, <u>Dependenstrebank</u>, <u>Aviskorpus</u>, <u>Bøker</u>)
- Lyddatasett (<u>Pressekonferanser</u>, <u>NB Samtale</u>)
- Verktøy (<u>Grafem-til-fonem-modeller</u>)
- Paralleldata (<u>nynorsk-bokmål</u>, <u>nno-eng + nob-eng</u>)



Språkmodeller

- Whisper (tale-til-tekst)
- BERT (token-embeddings)
- sBERT (setning-embeddings)
- GPT-J (generativ språkmodell)

Nettbiblioteket

https://www.nb.no/search

https://api.nb.no/

Kva er URN?

https://urn.nb.no/URN:NBN:no-nb_digibok_2011112808008

